

第三周实验报告

一，完成内容

- 1, 修改了上周的问题
- 2, 对模型 Qwen0.5B 运行结果的拒答情况进行统计
- 3, 验证格式会独立地让正常回答变长或变短
- 4, 人工检测先前代码对拒答情况判断的准确性
- 5, 跨模型 Qwen1.5B 验证同样的变体的拒答情况，并对比两个模型的拒答情况
- 6, 人工对错误拒答的内容进行分类
- 7, 提取模型 Qwen-0.5b 运行的 hidden states
- 8, 完成 false refusal rate 的热力图，对比不同问题类型与不同变体类型的拒答情况

二，做法

- 1, 用 refusal_detector.py 运行模型 Qwen-0.5b,输出 refusal_labels.csv 与 false_refusal_rate.csv
- 2, 运行 style_drift_analyzer.py, 输出 styler_drift.csv,在正常回答组里，进行变体与 plain 的输出长度中位数的对比
- 3, 人工从 refusal_labels.csv 中抽取样本计算 precision 与 recall
- 4, 另外运行完模型 Qwen-1.5b 后，得到 mutated_outputs_qwen1.5b.jsonl,再统计拒答情况输出 1.5b_refusal_labels.csv, 然后运行 cross_model_refusal.py, 输出 cross_model_refusal.csv,得出两个模型分别触发 false refusal 的情况
- 5, 人工从 cross_model_refusal.csv 中挑取样本进行拒答原因的分类
- 6, 用 extract_hidden_states.py 运行模型 Qwen-0.5b,输出 hidden_states.pt,并且选择一对 plain 与 json 进行每层的 cosine_similarity 的计算与对比
- 7, 画出了 false refusal rate 的热力图

三，初步结果

- 1, json 的格式容易触发角色扮演类问题的拒答，zh_en_mix 的格式也容易触发角色扮演类问题的拒答，翻译，代码和摘要没有对任何变体形式进行拒答
- 2, refusal_detector.py 的准确率达到 95%以上，召回率也达到 95%以上
- 3, 在正常回答中，zh_en_mix 会使回答变长两倍多，代码类几乎没有变化，json 会变短到 70%
- 4, 两个模型总的拒答数差不多，其中大约有一半是同一 prompt
- 5, 拒答的原因绝大类原因是误触发“无法提供事实”，有极少部分是误触发“政治敏感或隐私”
- 6, plain 与 json 每层的 cosine_similarity 大致符合逐层下降的趋势，但不是每一层严格符合
- 7, 热力图对 false_refusal_rate.csv 进行直观展示

四，遇到问题

- 1, 写 `extract_hidden_states.py` 比较难，有一些之前没有听说过的概念，需要学习了解
- 2, 分析结果时思路稍微有一些混乱，需要梳理清楚其中的逻辑与思路
- 3, 对于 plain 与 json 进行每层的 `cosine_similarity` 的计算与对比，本应该是逐层下降，但结果表明未严格遵循，只是趋势符合，对此很有困惑